

Tarea 02 – Componente práctico del curso

Jerónimo Ramos Ruiz

Director de Curso

SIXYEL JEYSON CASTAÑEDA CORONADO

Universidad Nacional Abierta y a Distancia UNAD

Escuela de Ciencias Básicas, Tecnología e Ingeniería (ECBTI)

Maestría en Ciencia de Datos y Analítica

2026

Tabla de contenidos

Introducción	4
Objetivos	5
Objetivo general.....	5
Objetivos específicos.....	5
Metodología.....	6
Resultados y conclusiones.....	9

No se encuentran elementos de tabla de ilustraciones.

Introducción

El presente reporte busca presentar el análisis de los datos proporcionados de diferentes restaurantes ubicados en varias ciudades de Colombia. El *dataset* proporciona información relevante como el tipo de comida ofrecida, calificaciones promedio de los usuarios, precios por persona y número de reseñas. Adicionalmente, incluye coordenadas geográficas para permitir la visualización geoespacial.

Se busca identificar patrones y relaciones significativas entre las categorías gastronómicas y su popularidad, así como los factores que influyen en el precio promedio por persona. Con este análisis, se busca ofrecer una visión clara sobre cómo la oferta y demanda de ciertos tipos de cocina varía entre ciudades facilitando la toma de decisiones en la industria gastronómica.

Objetivos

Objetivo general

Aplicar las habilidades adquiridas para seleccionar y analizar datos con el fin de obtener resultados relevantes, por medio de visualizaciones avanzadas y de forma clara y profesional.

Objetivos específicos

Identificar las categorías de comida más populares y los departamentos de Colombia con mayor concentración de restaurantes.

Crear una visualización geoespacial que permita comparar el comportamiento de los restaurantes según su ubicación.

Identificar correlaciones entre las variables del dataset utilizando gráficos de regresión.

Metodología

Para lograr los objetivos propuestos, se hizo uso del lenguaje de programación Python teniendo en cuenta que este cuenta con una amplia cantidad de librerías que permiten analizar fácilmente grandes cantidades de datos almacenados en diferentes formatos. A continuación, se presentan algunas de las librerías más importantes que fueron utilizadas y la versión en la que se desarrollaron las actividades con el fin de facilitar su reproducibilidad a futuro:

Librería	Versión	Función principal
Numpy	2.4.3	Realiza cálculos numéricos de alta velocidad y genera estructuras lógicas (como valores <code>np.nan</code> para identificar datos nulos).
Pandas	3.0.1	Carga, manipula y limpia el dataset desde archivos Excel; estructura los datos en tablas (<i>DataFrames</i>) y calcula estadísticas descriptivas básicas.
Matplotlib	3.11.1	Diseña y genera los gráficos estáticos del proyecto, tales como los histogramas de distribución y diagramas de barras de las categorías de comida
Geopandas	1.1.4	Extiende las funciones de Pandas para procesar objetos geoespaciales, permitiendo leer archivos vectoriales como Shapefiles (.shp) y realizar mapas de datos.
Folium	0.20.0	Genera el mapa interactivo en formato HTML para visualizar de forma dinámica los restaurantes sobre el mapa de Colombia con funciones de zoom y clusters.
Shapely	2.1.2	Realiza las operaciones matemáticas de geometría analítica detrás de escena (como la creación de objetos Point para las coordenadas y el cálculo de pertenencia).
Zipfile	2.33.1	Descomprime y extrae de forma segura el archivo .zip que contiene la cartografía digital para que GeoPandas pueda acceder al archivo .shp sin errores de formato.

Previo a cargar los datos en los mapas y generar las visualizaciones respectivas, se realizó un análisis exploratorio de los registros proporcionados. De este proceso, se identificó que se cuenta con 1000 registros, sin valores nulos en los campos registrados, los cuales se presentan a continuación:

Campo	Tipo de Variable
Nombre	Cualitativa Nominal (Texto)
Categoría	Cualitativa Nominal (Texto)
Calificación	Cuantitativa continua (Flotante)
Precio promedio (USD)	Cuantitativa continua (Flotante)
Número de reseñas	Cuantitativa continua (Entero)
Latitud	Cuantitativa continua (Flotante)
Longitud	Cuantitativa continua (Flotante)

Para iniciar el proceso de limpieza, una vez identificando los valores faltantes, se verificó que la ubicación geoespacial se encontrara dentro de los límites del mapa de Colombia, ya que es el área de interés. Con esto, se espera que todos los puntos se encuentren dentro del rango de Latitud = (-4.5; 13.5) y Longitud = (-79.0; -66.5). De este proceso, se identificaron 5 restaurantes por fuera de los límites definidos, por lo que, al ser una porción no representativa de la información, se procedió a eliminarlos.

Adicional al dataset proporcionado, se contó con un archivo comprimido que contiene los polígonos de Colombia y sus respectivos departamentos. Esto, junto con la información geoespacial de cada uno de los restaurantes, permitió identificar el departamento en el cual se encuentran ubicados. Para lograr este resultado, inicialmente se eliminaron los posibles errores que tuviera la información geoespacial proporcionada, como texto almacenado como número o espacios que alteraran los registros. Luego, con la ayuda de la biblioteca de geopandas se unió la información de los polígonos del shapefile con el dataset proporcionado y se asignó a cada restaurante un departamento.

Posterior a esto, se realizó un análisis inicial de los datos de interés, para este caso, la calificación, el precio promedio (USD) y el número de reseñas. De este análisis se obtuvo que se tienen registros con precios negativos, por lo que se procedió a eliminarlos antes de continuar con el análisis, dejando 993 registros para el análisis.

Una vez terminado el proceso de limpieza, se realizó un análisis descriptivo de las variables de interés, así como la generación de visualizaciones que permitan evidenciar el comportamiento de cada una con la ayuda de la librería de Seaborn. También, se identificaron las categorías más populares como los departamentos con mayor concentración de restaurantes. Con esta información, se generaron las siguientes interrogantes que permitirán profundizar el análisis:

¿Cuáles son las categorías de comida más costosas? ¿Qué tan confiables son las calificaciones dadas según la cantidad de reseñas? ¿Cuáles son las categorías más famosas por cada departamento?

Así mismo, se hizo uso de la librería Folium para crear un mapa interactivo donde se puede ver la ubicación de los restaurantes con marcadores interactivos que permiten acceder a la información específica de estos. También, se creó un mapa de coropletas, el cual es un tipo de mapa temático donde las regiones o áreas geográficas se sombrean o se llenan con distintos colores para mostrar cómo varía un valor estadístico, en este caso, el precio promedio por departamento y calificación.

Finalmente, se generó un dashboard con Plotly y Dash con el fin de contar con un informe interactivo que facilitara la visualización del comportamiento de las variables de interés y dieran respuesta a las preguntas planteadas sobre los datos proporcionados y ejemplificar la usabilidad e importancia de estas técnicas de visualización para la toma de decisiones basadas en datos.

Resultados y conclusiones

Luego de realizar la limpieza del dataset proporcionado y la asignación del departamento, se obtuvo la siguiente información:

Variable	Promedio	Desviación Estándar	Mínimo	Q1	Q2	Q3	Máximo
Calificación	2.98	1.16	1.00	2.00	3.00	4.00	5.00
Precio promedio (USD)	31.98	47.41	10.00	20.0	29.00	40.00	1000.00
Número de reseñas	271.59	129.85	50.00	159.00	269.00	275.00	499.00

Con el resultado anteriormente presentado, podemos observar que las calificaciones presentan un rango de 1.0 a 5.0, con una desviación estándar pequeña (1.16) con lo que se espera que los valores no se encuentren considerablemente alejados de la media (2.98). Por otra parte, se puede observar que en el 75% de los restaurantes registrados, el precio promedio de los platos no superó los 40 USD, con lo que el valor de 1000 USD puede tratarse de un valor atípico pero posible dentro del entorno analizado, por lo que no se elimina. Así mismo, podemos evidenciar una variedad de reseñas que van desde las 50 hasta las 499 por restaurante.

Sin embargo, con el fin de entender mejor la distribución de los datos de las variables de interés, se generaron los siguientes histogramas. En estos podemos identificar que la calificación no presenta un sesgo, presentando una distribución uniforme; lo cual puede estar indicando que se cuenta con variedad de opiniones. Este comportamiento es similar para el caso del número de reseñas, sin embargo, con las gráficas presentadas no podemos identificar una correlación entre el número de reseñas y la calificación asignada.

Por otra parte, podemos observar nuevamente el comportamiento antes visto con el precio, ya que la mayor cantidad de registros se encuentra concentrado en valores inferiores a los 100 USD, con unos valores extremos de 1000 USD.

```

1 # =====
2 # 4. VISUALIZACIONES CON MATPLOTLIB Y SEABORN
3 # =====
4 print("\n-- 4. GENERANDO VISUALIZACIONES --")
5
6 # Crear una figura compuesta (3 subgráficos en una fila para las distribuciones)
7 fig, axes = plt.subplots(3, 1, figsize=(18, 18))
8
9 # Gráfico 1: Distribución de Calificaciones
10 sns.histplot(df_clean['Calificación'], bins=15, kde=True, color='skyblue', ax=axes[0])
11 axes[0].set_title('Distribución de Calificaciones')
12 axes[0].set_xlabel('Calificación (estrellas)')
13 axes[0].set_ylabel('Frecuencia')
14
15 # Gráfico 2: Distribución de Precios Promedio
16 sns.histplot(df_clean['Precio promedio (USD)'], bins=20, kde=True, color='salmon', ax=axes[1])
17 axes[1].set_title('Distribución de Precios Promedio')
18 axes[1].set_xlabel('Precio ($ USD)')
19 axes[1].set_ylabel('Frecuencia')
20
21 # Gráfico 3: Distribución de Número de Reseñas
22 sns.histplot(df_clean['Número de reseñas'], bins=20, kde=True, color='lightgreen', ax=axes[2])
23 axes[2].set_title('Distribución de Reseñas (Escala Log)')
24 axes[2].set_xlabel('Número de Reseñas')
25 axes[2].set_ylabel('Frecuencia')
26
27 plt.tight_layout()
28 plt.show()

```

✓ 0.4s Python

Ilustración 1. Código de Python utilizado para la generación de los gráficos de distribución de las variables: calificaciones, precios y reseñas




Ilustración 2. Gráficas de dispersión de las variables: calificaciones, precios y reseñas

